

双引擎部署定位与端侧性能关系

TVM 负责固定形状极致性能，MNN 负责动态尺寸灵活部署



Tensor Virtual Machine

深度学习编译器路线
固定形状极致性能

端到端重建中位时间

(256×256 固定输入)

230.3 ms

核心技术栈

- Relax IR 多层次中间表示
- MetaSchedule 自动调优
 - 算子级手写优化
- (bias 融合/NEON 向量化)
- Cortex-A72 目标收敛

适用场景

标准化巡检图像批量重建
(分辨率统一的生产线场景)

协同互补



Mobile Neural Network

轻量级推理引擎路线
动态尺寸灵活部署

端到端平均时间

(300 张混合尺寸图像)

327.3 ms

核心技术栈

- 几何计算机制（光栅算子）
 - 半自动搜索机制
- 双 Interpreter 并行部署
- resizeTensor 动态适配
- 无需预缩放直接处理

适用场景

多源多尺寸图像实时处理
(分辨率不确定的混合输入)